

暨南大学

本科毕业论文（设计）开题报告

题目：基于提示词工程改良的生成式 AI
文本检测方法研究

学院：信息科学技术学院

专业：软件工程

学生姓名：张峻嘉

学号：2022170398

指导教师：孙玉霞

本科生院教务处

2025 年 12 月 27 日

一、选题依据（包括目的、意义、国内外研究现状和发展趋势）

随着大型语言模型（Large Language Models, LLMs）的快速发展，生成式人工智能已广泛应用于新闻写作、学术写作、问答与代码生成等场景，但也带来“内容来源不可追溯、学术不端与信息操纵”等风险，使得机器生成文本检测（Machine-Generated Text Detection）成为生成式 AI 安全的重要议题。并且随着大语言模型生成文本质量不断提升，机器生成文本检测成为学术与应用中的重要问题。现有研究提出了多种无需额外训练或弱监督的检测思路：例如 DetectGPT 利用“生成文本更可能处于模型对数概率函数的负曲率区域”这一性质，通过对文本进行扰动并比较概率曲率来判别其来源，但其计算往往较为昂贵；Fast-DetectGPT 在 DetectGPT 框架上进一步给出更高效的条件概率曲率计算方式，以降低检测开销。与此同时，也有工作从“重写”视角挖掘信号：Raidar 通过提示 LLM 对输入文本进行改写，并以改写前后编辑距离作为判别依据，发现模型对人类文本往往改动更大、对机器文本改动更小；DART 则在重写基础上引入 AMR 语义解析，利用原文与重写文本之间的语义差距进行判别并支持多模型设置。总体而言，现有方法在成本、跨域泛化、对新生成模型的鲁棒性以及提示词设计敏感性等方面仍存在挑战，这也为后续从“提示词集成与路由”等角度进一步提升重写式检测的稳定性与可迁移性提供了空间。

其中，Raidar 的优势在于：仅依赖 LLM 的“文本输出”即可工作，天然适配黑盒接口；并且在不同领域（论文、评论、代码、学生作文等）上都能观察到“人类文本更容易被重写、机器文本更不愿被改动”的不变性差异。然而，Raidar 同时明确指出：提示词工程会显著影响重写行为与编辑距离分布，理论上可通过“优化式搜索更好的重写提示词”进一步提升检测性能，但作者将该方向留作未来工作。这意味着——在重写式检测框架中，提示词本身既是“特征提取器”的控制旋钮，也是跨领域泛化的关键瓶颈。

近年来提示词工程研究表明，LLM 对提示词的措辞、结构与示例非常敏感：即使语义相近的提示，也可能诱导出不同的输出风格与编辑幅度，进而影响检测特征的统计稳定性。相比把“自动提示词优化”作为主要目标，本课题更聚焦于可控成本下的工程化方案：构建多样化的重写提示词池，并通过“提示词集成（ensemble）+ 路由（routing）”实现对不同体裁/领域输入的自适应选择。该思路与“提示词集成提升可靠性”以及“混合专家/混合提示词（Mixture-of-Prompts）按输入选择专家提示”的研究脉络一致：前者强调通过多提示生成与聚合降低偶然性，后者强调通过路由器将不同输入分配给更合适的提示以覆盖更大的问题空间。

基于以上现状，本课题拟在 Raidar 框架上开展两条主线的改良：（1）提示词集成：为同一文本使用多种重写提示词生成多份重写结果，提取编辑距离与一致性特征并进行稳健聚合；（2）提示词路由：设计轻量级路由器，以输入文本的语义表示（embedding）作为主要特征（可选融合长度、标点密度等低成本表层特征），动态选择最合适的提示词或提示词组合，以提升跨领域与跨模型的泛化性能。评测方面，将以 XSum（新闻）、PubMedQA（医学问答/摘要）与 WritingPrompts（创意写作）等数据为主，从而系统验证“提示词集成与路由”对重写式检测器的增益与边界。

二、研究内容（具体研究内容，重点解决的问题，预期结果）

本课题围绕“如何利用提示词工程改进重写式生成文本检测”展开，主要研究内容包括：

1. 提示词敏感性分析。在 Raidar 开源框架基础上复现单提示词检测流程，构建多种重写提示词（如流畅性改写、句法重组、同义替换、文体变换、压缩与扩展等），并引入长度控制策略。通过在 XSum、PubMedQA、WritingPrompts 等多域数据集上进行实验，分析不同提示词对检测准确率与稳定性的影响。

2. 多提示词集成方法。采用低成本的“多提示词一次重写 + 分数聚合”策略：对同一文本，使用 K 个重写提示词各生成 1 份改写文本，计算原文与改写文本之间的编辑距离/相似度作为“改动分数”，得到 K 个分数。随后在分数层面进行聚合：（a）简单平均得到总分；（b）在开发集上评估每个提示词的单独检测效果（如 F1/AUROC），以其表现作为权重进行加权平均得到总分。最后在开发集上选择阈值，将总分映射为 AI/HUMAN 标签。该方案避免多次采样带来的额外开销，同时保留多提示词互补带来的稳健性。

3. 提示词路由机制。构建轻量级路由器，以文本 embedding 作为主要输入特征：在开发集上对文本提取句向量，并学习“文本→专家提示词”的映射（例如基于聚类的最近中心路由或轻量分类器）。推理时对新文本仅需计算一次 embedding，即可选择最合适的提示词（或 Top-2 提示词）进行重写与评分，从而在控制成本的同时提升跨域适配性。

4. 自动化提示词优化（不作为主要任务）。借鉴 OPRO/APE 等自动提示词生成与搜索思想，作为扩展阅读与备选实验：若后续资源允许，可在小规模开发集上探索自动生成少量候选重写提示词；但本课题的核心工作仍以“提示词集成 + 路由机制”的可复现与可落地为主。

5. 综合检测框架构建与评测。将上述策略整合进 Raidar 框架，实现一个提示词鲁棒的重写式检测系统。重写器模型优先选用低成本 API/开源模型（如 OpenAI 的 gpt-4o-mini 或 gpt-3.5 系列，以及 DeepSeek 的 deepseek-chat 等），并系统比较不同重写器对检测效果、稳定性与成本的影响；在 XSum、PubMedQA、WritingPrompts 等多领域数据集上开展实验，评测跨领域的检测性能，并与 Raidar、DART、Fast-DetectGPT 等基线方法比较。

预期成果包括：（a）通过实验验证提示词工程在生成式文本检测中的作用，提出一套稳健的重写提示词设计原则；（b）提出提示词集成与提示词路由相结合的改良版 RaidAR 检测框架，提升跨生成模型与跨领域的泛化能力；（c）如时间与资源允许，探索自动化提示词优化并形成可复用的候选提示词库（暂定）；（d）形成可复现的实验代码与报告，力争在公开仓库中发布实现与实验配置。

三、研究方案（包括研究方法、技术路线、可行性分析等）

研究方法采用理论分析与实验验证相结合的方式，技术路线如下：

- (1) 文献调研与基线复现。梳理国内外生成式文本检测和提示词工程相关文献，对 Raidar 框架进行深入理解和复现，搭建起可运行的检测管线。
- (2) 提示词设计与实验评估。根据语言学和提示词工程经验设计多种重写指令，结合 DART 的长度约束策略统一重写文本的词数。利用低成本 API 重写器（如 gpt-4o-mini / gpt-3.5 / deepseek-chat）或本地开源模型批量生成重写版本，计算编辑距离、不变性、等变性、不确定性等特征，并在开发集上通过阈值选择或轻量分类器（如逻辑回归、支持向量机）进行检测与对比。
- (3) 集成与路由策略开发。在多提示词基础上开展集成实验，比较不同聚合方式的性能；选取适当的输入特征训练路由模型，实现按文本特征选择提示词，提高检测效率和准确率。
- (4) 自动提示词优化（暂定）。在主要工作完成后，若时间与资源允许，可尝试引入 OPRO/APE 等自动化提示词生成/搜索方法，以开发集检测指标（如 F1）作为评价函数，生成候选重写指令并进行筛选。该部分不纳入本课题的硬性进度安排。
- (5) 广泛实验与结果分析。在 XSum、WritingPrompts、PubMedQA 等多数据集以及不同生成模型上评测所提方法，分析跨域、跨模型的泛化能力，进行消融实验比较各模块的贡献。

可行性分析：Raidar 的代码已公开，重写阶段可利用开放 API 或本地大模型实现；所需数据集和评价指标公开可得；本人具备自然语言处理和机器学习基础，熟悉 Python 编程；

四、研究计划与进度安排

研究计划拟定如下：

2026.01（Raidar 复现完成）：完成 Raidar 基线系统复现与评测脚本跑通（重写 + 编辑距离特征 + 指标计算），并在选定数据集上复现实验结果；同时完成开发集/测试集划分与评测流程固化（随机种子、配置、运行命令），形成可重复的 baseline。Raidar 的核心做法为“提示 LLM 重写文本并计算编辑距离用于检测”，本月以完整复现为交付目标。

2026.02（集成完成）：构建 K 个重写提示词（3 - 8 个）并完成提示词敏感性实验；实现“多提示词一次重写 + 分数聚合”的集成检测策略（以均值/加权均值为主，权重由开发集单提示词表现确定），并在开发集完成阈值选择与主要消融（K 值、聚合方式、阈值策略）；完成低成本改写器 API 接口封装与小规模对比（如 gpt-4o-mini / gpt-3.5 / deepseek-chat），确定默认改写器与参数范围，为后续大规模实验做准备。

2026.03（路由完成）：实现基于 embedding 的提示词路由机制：在开发集计算文本 embedding，并采用聚类/最近中心或轻量分类器学习“文本 → 专家 prompt”的映射；在推理阶段对新文本仅需计算一次 embedding 即可完成路由选择。完成“无路由 vs 有路由”“单提示词 vs 集成”“不同路由策略”的对比与消融实验，并固化最终路由方案。MoP（Mixture-of-Prompts）相关开源实现作为工程基础支撑可复现与快速迭代。

2026.04（大规模实验 + 初稿 + 查重）：开展跨域与跨改写器的大规模实验，系统比较不同改写器对检测效果、稳定性与成本的影响；完成论文初稿与图表整理。2026.04.27 - 04.29 完成第一次查重，并据此集中修改（表述重写、引用规范、结构调整与结果解释）。

2026.05（终稿 + 答辩材料，全部在 5/9 前完成）：05.01 - 05.05：完成论文定稿、格式统一、参考文献核对与最终图表固化；补齐可复现实验说明（配置文件、依赖、脚本入口、运行命令）。05.06 - 05.08：完成答辩 PPT、讲稿与演示准备；完成代码与配置的最终整理（README、环境说明、复现实验步骤）。2026.05.09：参加毕业答辩（答辩前完成论文终稿、材料与代码整理）。

五、工作基础及条件

本人已系统学习《人工智能原理》、《强化学习》等课程，熟悉 Python 编程和主流深度学习框架，对大语言模型的应用具有一定实践经验。指导教师长期从事自然语言处理研究，拥有丰富的项目经验。课题所需的 Raidar 等开源代码已获得，重写阶段可使用低成本开放 API（如 gpt-4o-mini / gpt-3.5 或 deepseek-chat）或本地大模型生成改写文本，实验可以在学院服务器或云端 GPU 环境中完成。此外，相关数据集（如 XSum、WritingPrompts、PubMedQA 等）均可公开获取，文献资料齐全，因此研究具备良好的条件基础。此外，MoP（Mixture-of-Prompts）提供官方开源实现，可作为提示词专家构建与路由模块的参考与复现基础。

六、参考文献目录

- [1] Mao, C., Vondrick, C., Wang, H., & Yang, J. Raidar: geneRative AI Detection via Rewriting. ICLR 2024.
- [2] Park, H., Kim, B., & Kim, B. DART: An AIGT Detector using AMR of Rephrased Text. NAACL 2025 (Short Papers).
- [3] Mitchell, E., Lee, Y., Khazatsky, A., Manning, C. D., & Finn, C. DetectGPT: Zero-Shot Machine-Generated Text Detection using Probability Curvature. ICLR 2023.
- [4] Bao, G., Zhao, Y., Teng, Z., Yang, L., & Zhang, Y. Fast-DetectGPT: Efficient Zero-Shot Detection of Machine-Generated Text via Conditional Probability Curvature. ICLR 2024.
- [5] Gehrmann, S., Strobelt, H., & Rush, A. M. GLTR: Statistical Detection and Visualization of Generated Text. ACL 2019 (System Demonstrations).
- [6] Kirchenbauer, J., Geiping, J., Wen, Y., Katz, J., Miers, I., & Goldstein, T. A Watermark for Large Language Models. ICML 2023.
- [7] Wu, J., Li, X., et al. A Survey on LLM-Generated Text Detection. Computational Linguistics, 2025.
- [8] Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. BERTScore: Evaluating Text Generation with BERT. ICLR 2020.
- [9] Levenshtein, V. I. Binary Codes Capable of Correcting Deletions, Insertions and Reversals. Soviet Physics Doklady, 10(8):707–710, 1966.
- [10] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q. V., & Zhou, D. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS 2022.

- [11] Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., & Zhou, D. Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR 2023.
- [12] Zhou, Y., et al. Automatic Prompt Engineer (APE): Large Language Models Are Human-Level Prompt Engineers. arXiv, 2023.
- [13] Yang, C., Wang, X., Lu, Y., Liu, H., Le, Q. V., Zhou, D., & Chen, X. Large Language Models as Optimizers (OPRO). ICLR 2024.
- [14] Wang, R., An, S., Cheng, M., Zhou, T., Hwang, S. J., & Hsieh, C.-J. One Prompt is not Enough: Automated Construction of a Mixture-of-Expert Prompts. ICML 2024. (arXiv:2407.00256)
- [15] OpenAI. API Pricing. OpenAI Developer Platform, 2025. (online).
- [16] DeepSeek. Models & Pricing (API Docs). DeepSeek API Documentation, 2025. (online).
- [17] Wang, R. et al. Official implementation of Mixture-of-Prompts (MoP). GitHub repository: ruocwang/mixture-of-prompts, 2024. (online).

七、指导教师意见（重点考察选题意义、逻辑构建、写作安排等方面）

结论： ☐ 同意开题 ☐ 不同意开题

指导教师签名：

2025 年 12 月 27 日

八、答辩小组意见

结论: ☐通过 ☐不通过

答辩小组组长签字:

2025 年 12 月 29 日

备注: 1.开题报告原则上须达到以下字数要求: 理、工科类不少于 2000 字; 人文社科类不少于 3000 字;

2.此表同学生毕业论文(设计)一起存档。